

2026 교내 디지털 경진대회 개발 결과보고서

팀 명	솔라빔			부 문	☒ AI부문 ☐ SW부문
과 제 명	멀티모달 컨텍스트 기반 LLM Agent 차기 행동 의사결정 예측 결과보고서				
지도교수	성 명	최광훈 (서명)		소속(학과)	소프트웨어공학과
참여학생	성명	학과(전공)	학번	학년	연락처
	이재륜	소프트웨어공학과	213235	4	010-9210-3089
	박태은	소프트웨어공학과	213182	4	010-6473-5354
	최영현	소프트웨어공학과	213255	4	010-2414-6726
	김현규	소프트웨어공학과	214014	4	010-2505-4214
	김지환	소프트웨어공학과	213652	4	010-7723-2038

2026년 제10회 교내 디지털 경진대회 결과보고서를 제출합니다.

2026년 5월 25일

신청자(팀 대표) 이 재 룬 (서명) 

소프트웨어중심대학사업단장 귀하

결과보고서

1. 프로젝트 개요

본 프로젝트는 멀티모달 컨텍스트 기반 LLM Agent의 차기 행동 의사결정 예측을 목표로 한다. 사용자의 한국어 지시문과 사용 가능한 Tool 목록이 주어졌을 때, LLM Agent가 다음 단계에서 호출해야 할 Tool과 해당 arguments를 구조화된 JSON 형태로 예측하도록 구현하였다.

기존 챗봇이 단순히 자연어 답변을 생성하는 것과 달리, AI Agent는 사용자의 목적을 달성하기 위해 이메일 전송, 캘린더 등록, 웹 검색, 슬랙 메시지 전송 등 외부 Tool을 선택하고 호출해야 한다. 이때 중요한 것은 실제 Tool을 실행하기 전에 어떤 Tool을 선택할 것인지, 그리고 어떤 인자를 전달할 것인지를 정확히 결정하는 것이다.

본 프로젝트에서는 실제 이메일, 캘린더, 슬랙 등의 외부 서비스를 실행하지 않고, 실행 직전 단계의 행동 계획을 JSON으로 예측하는 데 집중하였다. 예측 결과는 정답 행동인 gold_action과 비교하여 Tool 선택 정확도와 argument 추출 성능을 평가하였다.

2. 프로젝트 주제의 필요성

AI Agent 시스템에서 Tool 선택 오류는 실제 서비스에서 큰 문제로 이어질 수 있다. 예를 들어 사용자가 “내일 오후 2시에 회의 일정 잡아줘”라고 요청했는데 Agent가 캘린더 Tool이 아닌 이메일 Tool을 선택하거나, 시간을 잘못 추출하면 잘못된 일정 등록 또는 잘못된 외부 동작이 발생할 수 있다.

따라서 Agent가 실제 Tool을 실행하기 전에 다음 행동을 정확히 예측하고 검증하는 과정은 Agent 시스템의 안전성과 신뢰성을 높이는 데 중요하다.

본 프로젝트는 먼저 텍스트 기반 Tool-Action 예측 파이프라인을 구현하고, 이후 이미지와 음성 컨텍스트를 추가하여 멀티모달 입력에서도 동일한 방식으로 행동 예측이 가능하도록 확장하였다. 이를 통해 텍스트, 이미지, 음성을 모두 활용하는 LLM Agent 행동 의사결정 예측 구조를 구현하였다.

3. 문제 정의

본 프로젝트의 입력은 사용자 지시문, 사용 가능한 Tool 목록, 선택적으로 제공되는 이미지 또는 음성 파일, 그리고 정답 행동 JSON인 gold_action으로 구성된다.

모델은 입력 정보를 바탕으로 다음과 같은 형식의 JSON 객체를 출력해야 한다.

```
{
  "tool_name": "string",
  "arguments": {
    "key": "value"
  }
}
```

예를 들어 사용자가 "이미지에 보이는 회의 정보를 캘린더에 추가해줘"라고 요청하고 이미지 안에 회의 제목, 날짜, 시간 정보가 포함되어 있다면, Agent는 실제 캘린더를 실행하는 것이 아니라 다음과 같은 행동 계획 JSON을 생성해야 한다.

```
{
  "tool_name": "calendar.create_event",
  "arguments": {
    "title": "Product Sync",
    "date": "Tomorrow",
    "time": "14:00"
  }
}
```

즉, 본 프로젝트의 핵심 문제는 사용자 지시와 컨텍스트를 해석하여 가장 적절한 Tool과 arguments를 예측하는 것이다.

Tool	목적
calendar.create_event	새 캘린더 일정 생성
calendar.update_event	기존 일정 수정
weather.search	날씨 조회
email.send	이메일 전송 행동 생성
slack.send_message	슬랙 메시지 전송 행동 생성
reminder.create	알림 생성
web.search	웹 검색
file.create_document	문서 생성
todo.create_task	할 일 추가
map.search_place	장소 검색
translate.text	번역
calculator.calculate	계산

이와 같이 다양한 Tool을 정의함으로써 단순 분류 문제가 아니라, 사용자 요청의 의미를 이해하고 적절한 외부 행동을 선택하는 Agent 의사결정 문제를 구성하였다.

5. 데이터 구성

5.1 텍스트 기반 데이터

텍스트 기반 평가 데이터는 한국어 사용자 지시문을 중심으로 구성하였다. 각 샘플은 사용자의 자연어 요청과 정답 Tool-Action JSON을 포함한다.

예를 들어 다음과 같은 샘플이 포함된다.

```
{
  "instruction": "내일 오후 2시에 팀 회의 일정 잡아줘.",
  "gold_action": {
    "tool_name": "calendar.create_event",
    "arguments": {
      "title": "팀 회의",
      "date": "내일",
      "time": "14:00"
    }
  }
}
```

텍스트 평가는 총 19개 샘플을 사용하였다. 캘린더, 날씨, 이메일, 웹 검색, 할 일 생성 등 여러 Tool을 포함하여 Tool 선택과 argument 추출 성능을 함께 평가하였다.

5.2 멀티모달 데이터

멀티모달 평가 데이터는 총 5개 샘플로 구성하였다. 이미지 샘플 3개와 음성 샘플 2개를 사용하였다.

유형	샘플 수	설명
이미지	3	회의 공지 이미지, 날씨 카드 이미지 등
음성	2	이메일 전송 요청, 슬랙 메시지 전송 요청


이미지와 음성 파일은 data/media/ 디렉터리에 저장하였다. 주요 파일은 다음과 같다.

파일	역할
meeting_notice.png	회의 제목, 날짜, 시간 정보를 담은 이미지
weather_card.png	위치와 날씨 정보를 담은 날씨 카드 이미지
email_instruction.wav	이메일 전송 요청 음성
slack_instruction.wav	슬랙 메시지 전송 요청 음성

멀티모달 데이터는 단순히 파일 경로만 저장한 것이 아니라, predict_gemini.py에서 실제 이미지와 음성 파일을 읽어 Gemini API의 입력으로 전달하도록 구현하였다. 따라서 OCR 결과나 음성 전사 텍스트를 미리 넣는 방식이 아니라, 이미지와 음성 파일 자체를 모델 입력에 포함하는 방식으로 평가하였다.

6. 구현 방식

전체 파이프라인은 다음과 같은 순서로 동작한다.



성능 비교를 위해 다음 네 가지 방법을 사용하였다.

방법	설명
Random	사용 가능한 Tool 중 하나를 무작위로 선택
Keyword	사용자 지시문의 키워드를 규칙 기반으로 매칭
Gemini	텍스트 instruction 기반 LLM 예측
Gemini-MM	이미지/음성 컨텍스트를 포함한 Gemini 멀티모달 예측

Random baseline은 최소 기준선 역할을 한다. Keyword baseline은 간단한 규칙 기반 접근이 어느 정도 성능을 낼 수 있는지 확인하기 위한 비교군이다. Gemini는 텍스트 기반 LLM 예측 성능을 확인하기 위한 방법이며, Gemini-MM은 이미지와 음성 컨텍스트까지 포함한 최종 멀티모달 예측 방법이다.

7. 평가 지표

평가에는 다음 지표를 사용하였다.

지표	설명
tool_accuracy	예측한 tool_name이 정답과 같은 비율
argument_f1	arguments의 key-value 쌍을 기준으로 계산한 F1 평균
normalized_argument_f1	시간 표현 등을 정규화한 뒤 계산한 Argument F1
exact_match	Tool 이름과 arguments가 모두 정확히 같은 비율
normalized_exact_match	정규화된 arguments 기준 Exact Match
json_success_rate	예측 JSON 생성 또는 파싱 성공 비율
hallucinated_tool_rate	존재하지 않는 Tool 이름을 예측한 비율
avg_latency_ms	평균 응답 지연 시간

특히 exact_match는 매우 엄격한 지표이다. 예를 들어 "14:00"과 "오후 2시"는 의미적으로 같지만 문자열이 다르기 때문에 strict 기준에서는 오답으로 처리된다. 이를

보완하기 위해 시간 표현 등을 정규화한 normalized 지표를 함께 계산하였다.

8. 실험 결과

최종 실험 결과는 다음과 같다.

Method	Total	Tool Accuracy	Argument F1	Normalized Argument F1	Exact Match
Random	19	0.1579	0.0000	0.0000	0.0000
Keyword	19	0.9474	0.4140	0.4140	0.1579
Gemini	19	1.0000	0.7088	0.8065	0.3684
Gemini-MM	5	1.0000	0.8333	0.8333	0.6000

Normalized Exact Match	JSON Success Rate	Hallucinated Tool Rate	Avg Latency ms
0.0000	1.0000	0.0000	0.00
0.1579	1.0000	0.0000	0.00
0.5789	1.0000	0.0000	2409.47
0.6000	1.0000	0.0000	3570.40

9. 결과 분석

9.1 Tool 선택 성능 분석

Gemini와 Gemini-MM은 모두 Tool Accuracy 1.0000을 기록하였다. 이는 모델이 텍스트 지시문뿐 아니라 이미지와 음성 컨텍스트가 포함된 상황에서도 어떤 Tool을 호출해야 하는지 정확하게 판단했음을 의미한다.

Random baseline의 Tool Accuracy는 0.1579로 낮게 나타났다. 이는 Tool 선택 문제가 단순한 무작위 선택으로 해결될 수 없으며, 사용자 의도와 문맥을 해석하는 과정이 필요하다는 점을 보여준다.

Keyword baseline은 Tool Accuracy 0.9474로 비교적 높은 성능을 보였다. 이는 현재 텍스트 데이터의 일부 지시문에 "메일", "일정", "날씨"처럼 Tool을 쉽게 추론할 수 있는 명확한 키워드가 포함되어 있기 때문이다. 그러나 Keyword 방식은 argument 추출 성능이 낮고, 이미지나 음성 같은 비정형 멀티모달 컨텍스트를 직접 처리하지 못

한다는 한계가 있다.

9.2 Argument 추출 성능 분석

Gemini의 strict Argument F1은 0.7088이고, normalized Argument F1은 0.8065로 나타났다. 정규화 후 점수가 상승한 이유는 "오후 2시"와 "14:00"처럼 의미는 같지만 표현이 다른 시간 값이 보정되었기 때문이다.

Gemini-MM의 Argument F1은 0.8333으로 나타났다. 이미지 샘플에서는 회의 제목, 날짜, 시간, 위치 정보를 비교적 정확하게 읽어 Tool arguments로 변환하였다. 음성 샘플에서도 이메일 수신자, 제목, 본문과 슬랙 채널, 메시지를 추출하였다.

다만 "Assignment submission"과 "Assignment Submission", "ten minutes"와 "10 minutes"처럼 의미는 같지만 표기가 다른 경우가 발생하였다. 이로 인해 Tool 선택은 정확했지만 Exact Match는 0.6000으로 제한되었다.

9.3 JSON 안정성 및 Tool Hallucination 분석

모든 방법에서 JSON Success Rate는 1.0000을 기록하였다. 이는 예측 결과가 정상적인 JSON 구조로 생성되었음을 의미한다.

또한 Hallucinated Tool Rate는 모든 방법에서 0.0000이었다. 즉, 모델이 tools.json에 존재하지 않는 Tool 이름을 생성하지 않았다. 실제 Agent 시스템에서는 존재하지 않는 Tool 호출이 실행 오류로 이어질 수 있으므로, 이 지표가 0이라는 점은 중요한 결과이다.

9.4 지연 시간 분석

Gemini의 평균 지연 시간은 약 2409.47ms, Gemini-MM의 평균 지연 시간은 약 3570.40ms로 나타났다. 멀티모달 입력은 이미지와 음성 파일을 함께 처리해야 하므로 텍스트 전용 방식보다 지연 시간이 더 길게 측정되었다.

MVP 수준에서는 사용 가능한 속도이지만, 실제 서비스 적용을 위해서는 prompt 축약, 입력 캐싱, 경량 모델 활용, 비동기 처리, 실패 시 retry/backoff 적용 등의 최적화가 필요하다.

10. 결론

본 프로젝트는 사용자 instruction과 Tool 목록을 기반으로 LLM Agent의 다음 Tool-Action JSON을 예측하고, 이를 정답 행동과 비교하여 정량적으로 평가하는 파이프라인을 구현하였다. 또한 이미지와 음성 컨텍스트를 실제 모델 입력에 포함하도록 확장하여 멀티모달 기반 Agent 행동 의사결정 예측 구조를 완성하였다.

실험 결과, Gemini는 텍스트 기반 평가에서 Tool Accuracy 1.0000, normalized Argument F1 0.8065를 기록하였다. 멀티모달 평가인 Gemini-MM은 이미지 3개와 음성 2개 샘플에서 Tool Accuracy 1.0000, Argument F1 0.8333, JSON Success Rate

1.0000을 기록하였다.

이를 통해 LLM Agent가 텍스트뿐만 아니라 이미지와 음성 컨텍스트를 활용하여 다음에 수행해야 할 행동을 예측할 수 있음을 확인하였다. 본 프로젝트는 실제 Tool 실행 이전 단계에서 Agent의 행동 의사결정을 검증하는 기초 파이프라인으로 활용될 수 있으며, 향후 더 많은 멀티모달 데이터와 안전성 검증 모듈을 추가하면 실제 Agent 서비스로 확장할 수 있을 것이다.